Arquitectura de las convocatorias adjudicadas en la contratación pública peruana

Web scraping, ensamblaje y análisis exploratorio desde el Portal de Datos Abiertos del OECE

Elisabeth Pacheco Rojas

Fundamentos de Programación para IA Generativa Aplicada
Programa de Especialización en IA Generativa aplicada a CCSS y Gestión Pública

Profesor: Alfonso Rodriguez
Asistente de curso: Jimena Yali

Abril de 2026

Drive: https://drive.google.com/drive/folders/1CMdgUrTVxSQx8EdtF3D8UJczvbLqCduu?usp=drive_link

Propósito de la presentación

Esta presentación sintetiza el desarrollo completo de la **Tarea Calificada 2** y responde de manera explícita a los tres requerimientos establecidos por el curso:

1. justificar el cambio de base de datos;
2. describir la estructura de la página web utilizada, señalando enlaces y verificando el tipo de código fuente;
3. explicar paso a paso el proceso de scrapeado y la organización de los datos extraídos.

El trabajo se estructuró en **tres partes dentro de un mismo Colab**: formalización del objeto e inspección inicial, descarga automatizada y auditoría, y ensamblaje con análisis exploratorio inicial.

Requerimientos del profesor

Tarea Calificada 2

1. Utilizar scripts de la clase de WebScrapping para scrapear las bases de datos utilizadas en el trabajo calificado.
2. Hacer una presentación indicando la estructura de la página web utilizada. La presentación debe señalar enlaces, verificar el tipo de código fuente y explicar paso a paso el proceso de scrapeado.
3. En caso de cambiar de base de datos, señalar claramente las razones.

La arquitectura de esta exposición fue diseñada precisamente para satisfacer esos tres puntos de manera ordenada, técnica y verificable.

Ubicación de la Tarea 2 dentro del curso

El syllabus del curso ubica este trabajo en la transición entre **manejo de datos, procesamiento de texto, APIs/automatización e introducción a GitHub**. La lógica del ejercicio no fue únicamente "extraer archivos", sino demostrar que las herramientas de programación del curso pueden traducirse en un **flujo de trabajo aplicado a gestión pública**.

- **Sesión 5:** NLP y tratamiento de texto.
- **Sesión 6:** Web scraping, HTML, Requests, BeautifulSoup y Selenium.
- **Sesión 7:** Automatización sobre portales públicos peruanos.

La Tarea 2 toma esas herramientas y las aplica al Portal de Datos Abiertos del OECE.

Justificación del cambio de base de datos

En la **Tarea 1** se trabajó con **ENAHO** porque esa fuente permitía reproducir los scripts vistos en clase sobre bases estructuradas, con énfasis en limpieza, integración de módulos, construcción de variables y análisis exploratorio. El objetivo era mostrar que los ejercicios del curso podían traducirse en una investigación social empírica inicial.

Para la **Tarea 2**, el núcleo metodológico cambió: ya no se trataba de operar sobre una base previamente descargada, sino de **inspeccionar una arquitectura web, identificar enlaces, verificar el tipo de fuente, automatizar descargas y construir un flujo reproducible de obtención de datos**. Por ello, se reemplazó ENAHO por el **Portal de Datos Abiertos del OECE**.

Razones sustantivas del cambio de base

Razón técnica

OECE permite ejercitar scraping, inspección de HTML, navegación asistida por JavaScript, descarga automatizada y auditoría de archivos.

Razón sustantiva

El tema de **contrataciones públicas** se vincula de manera inmediata con transparencia, rendición de cuentas, mercado de información estatal y análisis aplicado al Estado.

Razón formativa

El cambio no implica abandonar la rigurosidad académica, sino trasladarla a un objeto más cercano al campo profesional: pasar de una base estadística ya descargada a un **flujo de trabajo reproducible de captura, ensamblaje y exploración de datos administrativos**.

Delimitación precisa del objeto

La Tarea 2 **no** abordó el universo completo de las contrataciones públicas ni todos los módulos del Portal de Datos Abiertos del OECE. Para mantener un alcance **modesto, posible y lograble**, el objeto específico fue:

Objeto de trabajo

La arquitectura de acceso y descarga del módulo "Datos de la Convocatoria o Invitación"

La unidad inicial de trabajo no fue "la contratación pública peruana" en abstracto, sino los **archivos tabulares descargables** que la plataforma ofrece para ese módulo, organizados por año y por tipo de descarga.

Pregunta operativa y título del trabajo

Pregunta operativa

¿Cómo transformar el módulo *Datos de la Convocatoria o Invitación* del Portal de Datos Abiertos del OECE en un flujo reproducible de inspección, descarga, auditoría y análisis exploratorio inicial?

Título de trabajo

Arquitectura de las convocatorias adjudicadas en la contratación pública peruana: web scraping, ensamblaje y análisis exploratorio desde el Portal de Datos Abiertos del OECE

Enlaces utilizados

Portal principal

https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:datosabiertos.html/content?userid=public&password=key

Subpágina del módulo seleccionado

https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:
dataset.html/content?userid=public&password=key&pagina=convocatorias

Descripción institucional del portal

https://www.gob.pe/14272-acceder-al-portal-de-datos-abiertos-del-osce

Estos enlaces fueron documentados y almacenados en la bitácora del Colab como parte del inventario reproducible de la fuente.

Estructura general del portal OECE

La portada del portal organiza la información por **módulos funcionales**: plan anual de contrataciones, convocatorias, miembros de comité, adjudicación, ofertantes, proveedores, contrataciones directas, contratos, entre otros. Desde el punto de vista metodológico, esto indica que el portal no es un repositorio amorfo, sino una **interfaz jerarquizada de acceso a datos administrativos**.

En esta tarea se seleccionó únicamente el módulo de **convocatorias**.

Subpágina “Datos de la Convocatoria o Invitación”

La subpágina elegida presenta una estructura **seriada por años** (2018–2026). Cada bloque anual contiene:

- ícono de descarga,
- indicación de *Formato Excel*,
- botón *Descargar todos los procesos*,
- botón *Descargar solo subasta inversa electrónica*,
- botón *Descargar solo contratación directa*.

Esta repetición anual y modal fue la base de la estrategia de scraping.

Verificación del tipo de código fuente

Resultado principal

La inspección inicial mostró que la página se entrega como `text/html`. Sin embargo, la interfaz visible **no es enteramente HTML estático**: existe una capa de renderizado o inyección dinámica asistida por JavaScript.

- Se guardó el **HTML bruto** con `requests`.
- Se guardó el **HTML renderizado** con `Selenium`.
- La comparación permitió concluir que el scraping no debía pensarse solo como lectura directa del HTML, sino como identificación de **nodos, botones, atributos y eventos de descarga**.

Implicancia metodológica

El tipo de fuente justificó el uso combinado de `Requests + BeautifulSoup` para la inspección inicial y `Selenium` para la descarga controlada.

Evidencia de inspección del código fuente

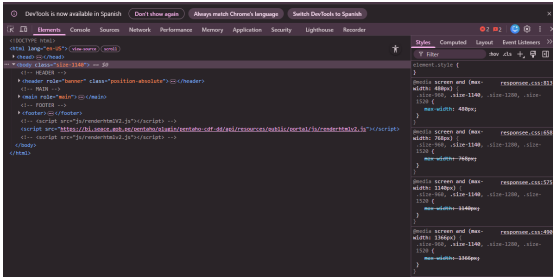

La evidencia visual del código fuente fue incorporada para documentar que la capa visible del portal depende de una estructura HTML servida al navegador y complementada por una lógica de renderizado.

Observación sobre el diccionario de datos

La hoja **"Convocatoria Diccionario"** permitió verificar que el módulo está bien definido desde el punto de vista estructural. El diccionario registra **28 variables** y combina información de:

- entidad,
- procedimiento,
- objeto contractual,
- montos,
- geografía del ítem,
- fechas relevantes.

Variables clave observadas: `CODIGOENTIDAD`, `ENTIDAD`, `TIPOENTIDAD`, `CODIGOCONVOCATORIA`, `DESCRIPCION_PROCESO`, `TIPO_COMPRA`, `OBJETOCONTRACTUAL`, `SISTEMA_CONTRATACION`, `MONTOREFERENCIAL`, `DEPARTAMENTO_ITEM`, `PROVINCIA_ITEM`, `DISTRITO_ITEM`, `MONEDA`, `FECHA_CONVOCATORIA`, `FECHAINTEGRACIONBASES` y `FECHAPRESENTACIONPROPUESTA`.

Arquitectura del Colab en tres partes

1. **Parte 1/3:** formalización del objeto, justificación del cambio de base, inspección estructural del portal, inventario inicial de enlaces y lectura del diccionario.
2. **Parte 2/3:** descarga automatizada controlada, inventario de botones renderizados, renombrado estandarizado, auditoría técnica de archivos y comparación estructural entre paquetes.
3. **Parte 3/3:** lectura y normalización de paquetes, construcción de una base principal de análisis, comparación de subconjuntos y producción de tablas y gráficos exploratorios.

Secuencia metodológica general

problema $\rightarrow$ fuente $\rightarrow$ inspección $\rightarrow$ descarga $\rightarrow$ auditoría $\rightarrow$ ensamblaje $\rightarrow$ análisis exploratorio

Estructura de carpetas de la Tarea 2

- `00_admin`
- `01_insumos`
- `02_fuente_web`
- `03_datos_brutos`
- `04_datos_procesados`
- `05_notebooks`
- `06_scripts`
- `07_resultados`
- `08_presentacion`
- `09_entrega`

Criterio de organización

La tarea fue ordenada separando **insumos**, **fuente web**, **datos brutos**, **datos procesados**, **scripts**, **resultados**, **presentación** y **entrega**. Esto permitió que el flujo de scraping y análisis permaneciera auditable en cada etapa.

Parte 1/3: productos generados

- inventario de estructura de carpetas;
- tabla de URLs de trabajo;
- guardado del HTML bruto del portal principal y de la subpágina;
- verificación de tipo de fuente y metadatos básicos;
- extracción inicial de títulos, encabezados y enlaces;
- inventario de años visibles;
- lectura y limpieza del diccionario de datos;
- bitácora metodológica de la parte 1.

Resultado de la Parte 1

Se pasó de una intuición general sobre OECE a una **formalización empírica mínima y reproducible del objeto de trabajo**.

Parte 2/3: estrategia de descarga controlada

1. revalidación de rutas y parámetros;
2. instalación de `Selenium` y `ChromeDriver`;
3. creación de un driver con permiso explícito de descarga;
4. guardado del HTML renderizado de la subpágina;
5. detección del contenedor del año y de los botones visibles;
6. localización del año objetivo (2022);
7. click automatizado sobre cada botón de descarga;
8. renombrado estandarizado y traslado de archivos a `03_datos_brutos/convocatorias/2022`.

Criterio de alcance

No se intentó descargar todo el portal. Se eligió una ventana **modesta y verificable**: el año 2022 y sus tres paquetes principales.

Paso a paso del proceso de scrapeado

1. **Identificación del sitio:** selección del Portal de Datos Abiertos del OECE y del módulo de convocatorias.
2. **Inspección estructural:** revisión del HTML bruto y del HTML renderizado; verificación de `text/html` y de la capa asistida por JavaScript.
3. **Selección de herramienta:** uso de `Requests` y `BeautifulSoup` para inspección inicial; uso de `Selenium` para descarga controlada.
4. **Escritura del código:** funciones para detectar el contenedor anual, identificar botones y esperar archivos descargados.
5. **Testing:** prueba inicial sobre un subconjunto (2022), verificación de directorio temporal y control de archivos `.crdownload`.
6. **Extracción:** descarga de tres archivos 2022 y renombrado estandarizado.
7. **Almacenamiento y auditoría:** inventario, comparación estructural y lectura inicial de los paquetes.

Resultado de la descarga controlada (2022)

Paquete	Filas	Columnas	Uso analítico
Todos los procesos	67,889	28	Base principal
Subasta inversa electrónica	8,046	28	Subconjunto comparativo
Contratación directa	5,465	28	Subconjunto comparativo

La coincidencia en el número de columnas y la compatibilidad estructural entre archivos confirmó que la estrategia de descarga controlada era estable y apta para la fase de ensamblaje.

Parte 2/3: productos generados

- HTML renderizado de la subpágina;
- inventario de botones renderizados;
- registro de descargas y renombrado estandarizado;
- inventario de archivos descargados;
- auditoría técnica de Excel;
- comparación estructural de columnas;
- muestra de lectura inicial de los tres paquetes;
- bitácora metodológica de la parte 2.

Resultado de la Parte 2

La inspección se transformó en una **extracción controlada, auditable y reproducible**.

Parte 3/3: decisión analítica central

Los tres paquetes 2022 **no** debían sumarse mecánicamente como si fueran universos independientes. Para evitar duplicación conceptual y empírica, se adoptó una decisión metodológica prudente:

Decisión de ensamblaje

- **Base principal de análisis:** archivo de *todos los procesos*.
- **Subconjuntos comparativos:** *subasta inversa electrónica* y *contratación directa*.

Esta decisión permitió distinguir entre universo general y subconjuntos específicos, en lugar de producir una base artificialmente inflada.

Construcción de la base limpia de trabajo

A partir del archivo principal se desarrollaron las siguientes operaciones:

1. normalización de nombres de columnas;
2. identificación semiautomática de variables clave;
3. tipificación de montos y fechas;
4. creación de una llave analítica de convocatoria;
5. limpieza básica de la descripción del proceso;
6. construcción de una tabla de trabajo con variables sustantivas.

Variables centrales: entidad, tipo de entidad, código de convocatoria, descripción del proceso, tipo de compra, objeto contractual, sistema de contratación, monto referencial, moneda, departamento, provincia, distrito y fechas de convocatoria.

Resumen general de la base principal 2022

Indicador	Valor
Registros totales	67,889
Convocatorias únicas	59,381
Entidades únicas	2,804
Objetos contractuales observados	4
Monto referencial con dato	67,889
Monto promedio	1,771,160.71
Monto mediano	189,911.67

La base principal no solo es estructuralmente consistente, sino suficientemente densa como para sostener una lectura exploratoria inicial del módulo de convocatorias.

Distribución por objeto contractual

Objeto contractual	Registros	Porcentaje
Bien	32,868	48.41 %
Servicio	22,742	33.50 %
Obra	7,946	11.71 %
Consultoría de Obra	4,333	6.38 %

Lectura inicial

El universo 2022 se concentra en bienes y servicios, mientras que obra y consultoría de obra representan subconjuntos menores pero relevantes para análisis sectorial posterior.

Top entidades por número de registros

Entidad	Registros
SEGURO SOCIAL DE SALUD	2,171
ORGANISMO DE EVALUACIÓN Y FISCALIZACIÓN AMBIENTAL	1,469
EJÉRCITO PERUANO	1,233
FUERZA AÉREA DEL PERÚ	955
PETRÓLEOS DEL PERÚ S.A.	671
MINISTERIO DE CULTURA	649
CENARES	592
GOBIERNO REGIONAL DE PUNO – SEDE CENTRAL	559
MARINA DE GUERRA DEL PERÚ	527
PROCIENCIA	502

Distribución territorial: departamentos con mayor número de registros

Departamento	Registros
Lima	18,564
Cusco	6,465
Áncash	4,113
Puno	3,030
Piura	2,937
Arequipa	2,802
La Libertad	2,544
Cajamarca	2,510
Junín	2,413
Ayacucho	2,265

La distribución territorial muestra un fuerte peso de Lima, pero también una presencia importante de territorios fuera de la capital, lo que sugiere potencial para análisis descentralizado de compras públi

Exploración textual mínima de la descripción del proceso

Se realizó una limpieza básica de la variable `descripcion_proceso` para explorar el vocabulario administrativo más recurrente. Entre los términos más frecuentes aparecieron:

distrito	provincia	departamento	mejoramiento
ejecucion	proyecto	mantenimiento	cusco
creacion	centro	agua	salud

La exploración textual no reemplaza un análisis NLP más profundo, pero sí muestra que el corpus administrativo del portal puede ser tratado con herramientas de texto en fases posteriores.

Balance metodológico de la Tarea 2

Lo que se demostró

1. la base de datos podía cambiarse con justificación metodológica clara;
2. el portal seleccionado podía inspeccionarse y documentarse estructuralmente;
3. el tipo de fuente y el patrón de descarga podían verificarse;
4. era posible construir un scraper controlado y auditable sobre un subconjunto anual;
5. los archivos descargados podían transformarse en una base administrativa analizable.

Lo que deliberadamente no se hizo

No se intentó descargar todo el portal ni producir inferencias causales. La tarea se concentró en un ejercicio de **captura, ensamblaje y exploración inicial**.

Respuesta explícita a los requerimientos de la Tarea 2

Requerimiento del profesor	Cómo se respondió
Justificar el cambio de base	Se explicó el tránsito ENAHO $\rightarrow$ OECE desde una lógica de scraping, automatización y gestión pública.
Señalar enlaces	Se documentaron el portal principal, la subpágina de convocatorias y la referencia institucional en `gob.pe`.
Verificar el tipo de código fuente	Se compararon HTML bruto y HTML renderizado, identificando una interfaz `text/html` con capa dinámica.
Explicar paso a paso el scrapeo	Se organizó el proceso en tres partes: inspección, descarga controlada, auditoría y ensamblaje.

Conclusiones

1. La Tarea 2 confirmó que el módulo *Datos de la Convocatoria o Invitación* del portal OECE puede convertirse en una **fuente administrativa operativa** para análisis aplicado en gestión pública.
2. El trabajo mostró que el scraping no comienza con el click, sino con la **delimitación del objeto, la inspección estructural y la verificación del tipo de fuente**.
3. La estrategia de trabajar en tres partes dentro de un mismo Colab permitió mantener un flujo de trabajo **modesto, claro, auditado y reproducible**.
4. La tarea no agotó el portal OECE, pero dejó construida una base metodológica sólida para ampliar la extracción en fases posteriores o para derivarla hacia el trabajo final.

Referencias y fuentes de trabajo I

- Fundamentos de Programación para IA Generativa. *Indicaciones para la Tarea Calificada 2 y Trabajo Final*. Documento del curso.
- Programa de Especialización en Inteligencia Artificial Generativa aplicada a CCSS y Gestión Pública. *Fundamentos de Programación para IA Generativa Aplicada*. Syllabus del curso.
- Pacheco Rojas, E. *Tarea 2.ipynb / tarea_2.py*. Material reproducible elaborado en Google Colab.
- Portal de Datos Abiertos del OECE. Portal principal. https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:datosabiertos.html/content?userid=public&password=key
- Portal de Datos Abiertos del OECE. Subpágina *Datos de la Convocatoria o Invitación*. https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:dataset.html/content?userid=public&password=key&pagina=convocatorias
- Gobierno del Perú. *Acceder al portal de datos abiertos del OSCE*. https://www.gob.pe/14272-acceder-al-portal-de-datos-abiertos-del-osce

Gracias

Elisabeth Pacheco Rojas