Diseño e implementación de un workflow reproducible

para la descarga, auditoría, ensamblaje y visualización de convocatorias públicas del OECE

Elisabeth Pacheco Rojas

Fundamentos de Programación para IA Generativa Aplicada
Programa de Especialización en IA Generativa aplicada a CCSS y Gestión Pública

Profesor: Alfonso Rodriguez
Asistente de curso: Jimena Yali

Abril de 2026

Drive de trabajo: IA Generativa para CCSS / Trabajo Final
GitHub: enlace por agregar al cierre del proyecto

Propósito de la presentación

Esta presentación sintetiza el **Trabajo Final del curso** y muestra cómo el proyecto responde a las exigencias académicas del profesor mediante una propuesta técnico-metodológica clara, reproducible y aplicable a gestión pública.

1. presentar la **propuesta de mejora de flujo de trabajo**;
2. identificar las **herramientas de IA generativa** utilizables en cada sección;
3. explicitar las **herramientas de programación** implementadas;
4. demostrar la **relevancia del tema** para CCSS, políticas públicas y gestión pública.

El trabajo se desarrolló en un mismo Colab y se organizó como un **workflow reproducible en tres partes**: inspección estructural, descarga y auditoría multianual, y ensamblaje con visualización exploratoria.

Requerimientos del profesor y respuesta del proyecto

Exigencia del curso	Respuesta del Trabajo Final
Propuesta de mejora de flujo de trabajo o diseño de aplicación	Se construyó un workflow modular para inspección, descarga, auditoría, ensamblaje y visualización de convocatorias públicas del OECE.
Herramientas de IA generativa por sección	Se identifican usos diferenciados de IA para diseño del pipeline, documentación, refactorización, revisión y presentación.
Elementos de programación implementados	Se explicitan paquetes, funciones y procesos de webscraping, manejo de bases, visualización y exportación.
Evaluación por relevancia y claridad técnica	La exposición se organiza para responder explícitamente a relevancia sustantiva, claridad metodológica y claridad computacional.

Problema, objeto y alcance

Problema general

Aunque el Portal de Datos Abiertos del OECE ofrece archivos descargables de convocatorias públicas organizados por año y tipo de descarga, su aprovechamiento analítico es fragmentado si no se dispone de un flujo reproducible que integre inspección, descarga, auditoría, ensamblaje y visualización.

Objeto de trabajo

El módulo **"Datos de la Convocatoria o Invitación"** del portal OECE, entendido como una arquitectura visible y descargable organizada por año y por paquete.

Alcance

- todos los años visibles en el portal;
- tres tipos de descarga por año;
- workflow técnico, no observatorio exhaustivo;
- outputs descriptivos y reproducibles.

Relevancia para CCSS, políticas y gestión pública

CCSS

Convierte una fuente administrativa estatal en un objeto reproducible para estudiar temporalidad, territorio, actores públicos y lenguaje administrativo.

Políticas públicas

Fortalece transparencia, trazabilidad, monitoreo y producción de evidencia descriptiva sobre convocatorias públicas.

Gestión pública

Muestra cómo programación, documentación y control de datos pueden integrarse en un flujo de trabajo útil para análisis aplicado al Estado.

Idea central

El valor del proyecto no es solo *extraer archivos*, sino demostrar que una fuente web dinámica puede convertirse en una **infraestructura de trabajo reproducible y auditada**.

Fuente de datos y enlaces de trabajo

Portal principal

https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:datosabiertos.html/content?userid=public&password=key

Subpágina de convocatorias

https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:dataset.html/content?userid=public&password=key&pagina=convocatorias

Referencia institucional

https://www.gob.pe/14272-acceder-al-portal-de-datos-abiertos-del-osce

La fuente fue tratada como **objeto técnico documentado**: se guardó HTML bruto, HTML renderizado, inventario de años, inventario de botones, logs y manifests de seguimiento.

Arquitectura general de la página y tipo de fuente

La subpágina presenta una **estructura seriada por años**. Cada bloque anual replica una lógica estable:

- etiqueta del año,
- referencia a formato Excel,
- botón de todos los procesos,
- botón de subasta inversa,
- botón de contratación directa.

Diagnóstico técnico

La página se entrega como `text/html`, pero la capa visible depende de renderizado asistido por navegador. Por ello se usó:

- `requests` para HTML bruto;
- `BeautifulSoup` para inspección inicial;
- `Selenium` para detección visible y descarga.

La propuesta de mejora: del scraping aislado al workflow reproducible

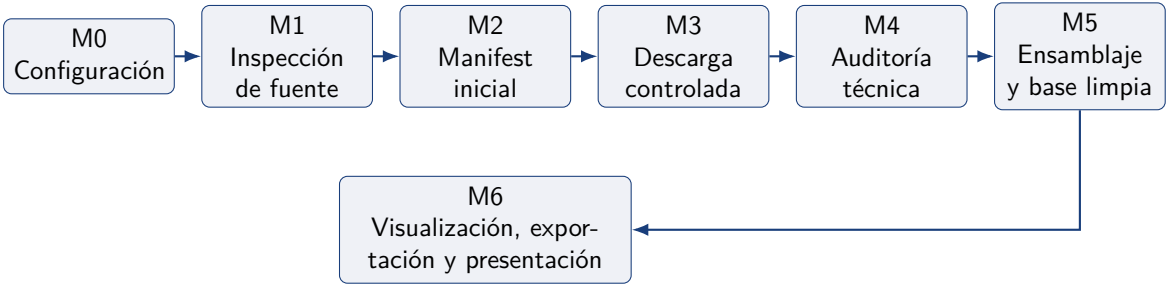

La mejora no consiste en *descargar más*, sino en pasar de una práctica puntual de scraping a una **arquitectura modular de trabajo**, con entradas, salidas, control de errores y trazabilidad documental.

Estructura reproducible del proyecto

Carpetas principales

- `00_admin`
- `02_fuente_web`
- `03_datos_brutos`
- `04_datos_procesados`
- `07_resultados`
- `08_presentacion`
- `09_entrega`

Función metodológica

- separar evidencia web, brutos y procesados;
- conservar logs y manifests;
- exportar tablas y figuras;
- sostener la auditabilidad del flujo.

Principio organizador

La carpeta no es un detalle administrativo: es parte del método. Permite que el proyecto sea legible, replicable y defendible.

Secuencia técnica del desarrollo en Colab

Parte	Desarrollo principal
Parte 1/3	creación de carpetas, validación de URLs, guardado de HTML bruto y renderizado, detección de años visibles, inventario de botones y manifest inicial.
Parte 2/3	plan de descarga multianual, Selenium con permisos de descarga, renombrado, inventario físico, auditoría de Excel, consistencia estructural y actualización del manifest.
Parte 3/3	lectura multianual, base comparativa, base principal, variables clave, tabla limpia, cobertura anual, figuras, resumen de montos, exploración textual y manifest final.

Herramientas de IA generativa por sección del trabajo

Sección	Uso principal de IA generativa	Resultado esperado
Diseño del proyecto	apoyo para formular problema, objeto, pregunta y arquitectura del workflow	coherencia metodológica entre fuente, módulos y outputs
Inspección y scraping	asistencia para revisar selectores, refactorizar funciones y depurar lógica de navegación	código más legible, estable y comentado
Auditoría y ensamblaje	apoyo para revisar consistencia entre pasos, manifests y reglas de integración	control de calidad y reducción de errores de ensamblaje
Documentación	apoyo para redactar markdown, README, bitácoras y narrativa técnica	trazabilidad y presentación académica más clara
Presentación final	apoyo para traducir el workflow a una exposición ordenada y defensible	comunicación clara de decisiones, herramientas y relevancia

Elementos de programación implementados

Dimensión	Herramientas	Implementación
Web scraping	`requests`, `BeautifulSoup`, `selenium`, `webdriver-manager`	inspección de HTML bruto, renderizado visible, localización de botones y descarga controlada
Manejo de bases	`pandas`, `numpy`, `openpyxl`, `pathlib`	manifests, inventarios, auditoría de hojas, lectura multianual y ensamblaje de bases
Limpieza y normalización	`re`, `unicodedata`	normalización de columnas, nombres de archivos, textos y llaves analíticas
Visualización	`matplotlib`	series anuales, trayectorias mensuales, distribución territorial, montos y frecuencias textuales
Exportación	escritura de `csv`, figuras `png` y estructura de carpetas	outputs trazables para presentación, entrega y futura publicación en GitHub

Controles de calidad del workflow

Criterios técnicos

- reproducibilidad;
- modularidad;
- escalabilidad multianual;
- auditabilidad;
- reejecución controlada.

Mecanismos concretos

- manifests inicial, de descarga, de auditoría y de ensamblaje;
- logs de scraping y lectura;
- inventario físico de archivos;
- auditoría de hojas y columnas;
- separación entre brutos, procesados y resultados.

Decisión analítica central de ensamblaje

Principio metodológico

Los tres paquetes descargados no deben sumarse mecánicamente como si fueran universos independientes. Para evitar inflación conceptual y empírica, se distingue entre **universo general** y **subconjuntos comparativos**.

Base principal

todos_los_procesos

Subconjuntos comparativos

solo_subasta_inversa_electronica

solo_contratacion_directa

Esta decisión permite mantener consistencia analítica entre cobertura general del portal y paquetes especializados.

Outputs principales producidos por el workflow

- HTML bruto y renderizado;
- inventario de años y botones;
- manifest inicial;
- plan de descarga multianual;
- registro de descargas;
- inventario físico de archivos;
- auditoría técnica de Excel;
- comparación estructural de columnas;
- base comparativa multianual;
- base principal multianual;
- tabla limpia de trabajo;
- cobertura anual;
- trayectoria mensual;
- distribución por objeto contractual;
- top de entidades;
- distribución territorial;
- resumen de montos;
- exploración textual mínima.

Resultados que la presentación puede mostrar

Nivel estructural

- años visibles detectados en la página;
- paquetes descargables por año;
- consistencia de columnas entre archivos;
- número de archivos y cobertura del workflow.

Nivel exploratorio

- distribución por objeto contractual;
- entidades con mayor volumen de registros;
- departamentos con mayor presencia de convocatorias;
- frecuencia de términos en la descripción del proceso;
- trayectoria mensual de convocatorias.

El proyecto no se presenta como inferencia causal exhaustiva, sino como un **workflow reproducible que produce una base administrativa lista para análisis descriptivo y ampliaciones posteriores**.

GitHub como capa final de reproducibilidad

Rol de GitHub en este proyecto

GitHub no se plantea como sustituto de Colab, sino como capa final de versionamiento, documentación y presentación pública del workflow.

- Colab y Drive: entorno de ejecución y almacenamiento operativo.
- GitHub: repositorio curado con notebook estable, scripts, README, estructura de carpetas y outputs seleccionados.
- Presentación final: incluirá el enlace del repositorio una vez cerrado el proyecto.

`[Agregar aquí el enlace del repositorio GitHub al momento de la entrega]`

Conclusiones

1. El Trabajo Final responde al curso como una **propuesta de mejora de flujo de trabajo**, no como scraping aislado.
2. La relevancia del tema se sostiene por su utilidad para **CCSS, políticas públicas y gestión pública**.
3. Las **herramientas de IA generativa** fueron ubicadas con claridad según la función que cumplen en diseño, revisión, documentación y presentación.
4. Los **elementos de programación** quedaron explicitados en webscraping, manejo de bases, visualización y exportación.
5. El proyecto deja construida una base metodológica sólida para su formalización final en **GitHub** y para ampliaciones posteriores del análisis.

Gracias

Elisabeth Pacheco Rojas

Trabajo Final del curso:

Workflow reproducible para convocatorias públicas del OECE