Elisabeth Pacheco Rojas

Fundamentos de Programación para IA Generativa Aplicada
Programa de Especialización en IA Generativa aplicada a CCSS y Gestión Pública

Abril de 2026

Esta presentación sintetiza el desarrollo completo de la **Tarea Calificada 2** y responde de manera explícita a los tres requerimientos establecidos por el curso:

1. justificar el cambio de base de datos;
2. describir la estructura de la página web utilizada, señalando enlaces y verificando el tipo de código fuente;
3. explicar paso a paso el proceso de scrapeado y la organización de los datos extraídos.

El trabajo se estructuró en **tres partes dentro de un mismo Colab**: formalización del objeto e inspección inicial, descarga automatizada y auditoría, y ensamblaje con análisis exploratorio inicial.

## Tarea Calificada 2

1. Utilizar scripts de la clase de WebScrapping para scrapear las bases de datos utilizadas en el trabajo calificado.
2. Hacer una presentación indicando la estructura de la página web utilizada. La presentación debe señalar enlaces, verificar el tipo de código fuente y explicar paso a paso el proceso de scrapeado.
3. En caso de cambiar de base de datos, señalar claramente las razones.

La arquitectura de esta exposición fue diseñada precisamente para satisfacer esos tres puntos de manera ordenada, técnica y verificable.

El syllabus del curso ubica este trabajo en la transición entre **manejo de datos, procesamiento de texto, APIs/automatización e introducción a GitHub**. La lógica del ejercicio no fue únicamente "extraer archivos", sino demostrar que las herramientas de programación del curso pueden traducirse en un **flujo de trabajo aplicado a gestión pública**.

- **Sesión 5:** NLP y tratamiento de texto.
- **Sesión 6:** Web scraping, HTML, Requests, BeautifulSoup y Selenium.
- **Sesión 7:** Automatización sobre portales públicos peruanos.

La Tarea 2 toma esas herramientas y las aplica al Portal de Datos Abiertos del OECE.

En la **Tarea 1** se trabajó con **ENAHO** porque esa fuente permitía reproducir los scripts vistos en clase sobre bases estructuradas, con énfasis en limpieza, integración de módulos, construcción de variables y análisis exploratorio. El objetivo era mostrar que los ejercicios del curso podían traducirse en una investigación social empírica inicial.

Para la **Tarea 2**, el núcleo metodológico cambió: ya no se trataba de operar sobre una base previamente descargada, sino de **inspeccionar una arquitectura web, identificar enlaces, verificar el tipo de fuente, automatizar descargas y construir un flujo reproducible de obtención de datos**. Por ello, se reemplazó ENAHO por el **Portal de Datos Abiertos del OECE**.

## Razón técnica

OECE permite ejercitar scraping, inspección de HTML, navegación asistida por JavaScript, descarga automatizada y auditoría de archivos.

## Razón sustantiva

El tema de **contrataciones públicas** se vincula de manera inmediata con transparencia, rendición de cuentas, mercado de información estatal y análisis aplicado al Estado.

## Razón formativa

El cambio no implica abandonar la rigurosidad académica, sino trasladarla a un objeto más cercano al campo profesional: pasar de una base estadística ya descargada a un **flujo de trabajo reproducible de captura, ensamblaje y exploración de datos administrativos**.

La Tarea 2 **no** abordó el universo completo de las contrataciones públicas ni todos los módulos del Portal de Datos Abiertos del OECE. Para mantener un alcance **modesto, posible y lograble**, el objeto específico fue:

**Objeto de trabajo**

**La arquitectura de acceso y descarga del módulo "Datos de la Convocatoria o Invitación"**

La unidad inicial de trabajo no fue "la contratación pública peruana" en abstracto, sino los **archivos tabulares descargables** que la plataforma ofrece para ese módulo, organizados por año y por tipo de descarga.

## Pregunta operativa

¿Cómo transformar el módulo *Datos de la Convocatoria o Invitación* del Portal de Datos Abiertos del OECE en un flujo reproducible de inspección, descarga, auditoría y análisis exploratorio inicial?

## Título de trabajo

**Arquitectura de las convocatorias adjudicadas en la contratación pública peruana: web scraping, ensamblaje y análisis exploratorio desde el Portal de Datos Abiertos del OECE**

### Portal principal

https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:datosabiertos.html/content?userid=public&passwor

### Subpágina del módulo seleccionado

https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:dataset.html/content?userid=public&password=key&

### Descripción institucional del portal

https://www.gob.pe/14272-acceder-al-portal-de-datos-abiertos-del-osce

Estos enlaces fueron documentados y almacenados en la bitácora del Colab como parte del inventario reproducible de la fuente.

La portada del portal organiza la información por **módulos funcionales**: plan anual de contrataciones, convocatorias, miembros de comité, adjudicación, ofertantes, proveedores, contrataciones directas, contratos, entre otros. Desde el punto de vista metodológico, esto indica que el portal no es un repositorio amorfo, sino una **interfaz jerarquizada de acceso a datos administrativos**.

En esta tarea se seleccionó únicamente el módulo de **convocatorias**.

Insertar aquí la imagen:
`imagenes/oece_portada.png`

La subpágina elegida presenta una estructura **seriada por años** (2018–2026). Cada bloque anual contiene:

- ícono de descarga,
- indicación de *Formato Excel*,
- botón *Descargar todos los procesos*,
- botón *Descargar solo subasta inversa electrónica*,
- botón *Descargar solo contratación directa*.

Esta repetición anual y modal fue la base de la estrategia de scraping.

Insertar aquí la imagen:
`imagenes/oece_convocatorias.png`

## Resultado principal

La inspección inicial mostró que la página se entrega como `text/html`. Sin embargo, la interfaz visible **no es enteramente HTML estático**: existe una capa de renderizado o inyección dinámica asistida por JavaScript.

- Se guardó el **HTML bruto** con `requests`.
- Se guardó el **HTML renderizado** con `Selenium`.
- La comparación permitió concluir que el scraping no debía pensarse solo como lectura directa del HTML, sino como identificación de **nodos, botones, atributos y eventos de descarga**.

## Implicancia metodológica

El tipo de fuente justificó el uso combinado de `Requests + BeautifulSoup` para la inspección inicial y `Selenium` para la descarga controlada.

Insertar aquí la imagen:
`imagenes/oece_codigo_fuente.png`

La evidencia visual del código fuente fue incorporada para documentar que la capa visible del portal depende de una estructura HTML servida al navegador y complementada por una lógica de renderizado.

La hoja **“Convocatoria Diccionario”** permitió verificar que el módulo está bien definido desde el punto de vista estructural. El diccionario registra **28 variables** y combina información de:

- entidad,
- procedimiento,
- objeto contractual,
- montos,
- geografía del ítem,
- fechas relevantes.

Variables clave observadas: `CODIGOENTIDAD`, `ENTIDAD`, `TIPOENTIDAD`, `CODIGOCONVOCATORIA`, `DESCRIPCION_PROCESO`, `TIPO_COMPRA`, `OBJETOCONTRACTUAL`, `SISTEMA_CONTRATACION`, `MONTOREFERENCIAL`, `DEPARTAMENTO_ITEM`, `PROVINCIA_ITEM`, `DISTRITO_ITEM`, `MONEDA`, `FECHA_CONVOCATORIA`, `FECHAINTEGRACIONBASES` y `FECHAPRESENTACIONPROPUESTA`.

1. **Parte 1/3:** formalización del objeto, justificación del cambio de base, inspección estructural del portal, inventario inicial de enlaces y lectura del diccionario.
2. **Parte 2/3:** descarga automatizada controlada, inventario de botones renderizados, renombrado estandarizado, auditoría técnica de archivos y comparación estructural entre paquetes.
3. **Parte 3/3:** lectura y normalización de paquetes, construcción de una base principal de análisis, comparación de subconjuntos y producción de tablas y gráficos exploratorios.

### Secuencia metodológica general

problema $\rightarrow$ fuente $\rightarrow$ inspección $\rightarrow$ descarga $\rightarrow$ auditoría $\rightarrow$ ensamblaje $\rightarrow$ análisis exploratorio

- `00_admin`
- `01_insumos`
- `02_fuente_web`
- `03_datos_brutos`
- `04_datos_procesados`
- `05_notebooks`
- `06_scripts`
- `07_resultados`
- `08_presentacion`
- `09_entrega`

## Criterio de organización

La tarea fue ordenada separando **insumos**, **fuente web**, **datos brutos**, **datos procesados**, **scripts**, **resultados**, **presentación** y **entrega**. Esto permitió que el flujo de scraping y análisis permaneciera auditable en cada etapa.

- inventario de estructura de carpetas;
- tabla de URLs de trabajo;
- guardado del HTML bruto del portal principal y de la subpágina;
- verificación de tipo de fuente y metadatos básicos;
- extracción inicial de títulos, encabezados y enlaces;
- inventario de años visibles;
- lectura y limpieza del diccionario de datos;
- bitácora metodológica de la parte 1.

### Resultado de la Parte 1

Se pasó de una intuición general sobre OECE a una **formalización empírica mínima y reproducible del objeto de trabajo**.

1. revalidación de rutas y parámetros;
2. instalación de `Selenium` y `ChromeDriver`;
3. creación de un driver con permiso explícito de descarga;
4. guardado del HTML renderizado de la subpágina;
5. detección del contenedor del año y de los botones visibles;
6. localización del año objetivo (2022);
7. click automatizado sobre cada botón de descarga;
8. renombrado estandarizado y traslado de archivos a `03_datos_brutos/convocatorias/2022`.

## Criterio de alcance

No se intentó descargar todo el portal. Se eligió una ventana **modesta y verificable**: el año 2022 y sus tres paquetes principales.

1. **Identificación del sitio:** selección del Portal de Datos Abiertos del OECE y del módulo de convocatorias.
2. **Inspección estructural:** revisión del HTML bruto y del HTML renderizado; verificación de `text/html` y de la capa asistida por JavaScript.
3. **Selección de herramienta:** uso de `Requests` y `BeautifulSoup` para inspección inicial; uso de `Selenium` para descarga controlada.
4. **Escritura del código:** funciones para detectar el contenedor anual, identificar botones y esperar archivos descargados.
5. **Testing:** prueba inicial sobre un subconjunto (2022), verificación de directorio temporal y control de archivos `.crdownload`.
6. **Extracción:** descarga de tres archivos 2022 y renombrado estandarizado.
7. **Almacenamiento y auditoría:** inventario, comparación estructural y lectura inicial de los paquetes.

| Paquete | Filas | Columnas | Uso analítico |
|---|---|---|---|
| Todos los procesos | 67,889 | 28 | Base principal |
| Subasta inversa electrónica | 8,046 | 28 | Subconjunto comparativo |
| Contratación directa | 5,465 | 28 | Subconjunto comparativo |

La coincidencia en el número de columnas y la compatibilidad estructural entre archivos confirmó que la estrategia de descarga controlada era estable y apta para la fase de ensamblaje.

- HTML renderizado de la subpágina;
- inventario de botones renderizados;
- registro de descargas y renombrado estandarizado;
- inventario de archivos descargados;
- auditoría técnica de Excel;
- comparación estructural de columnas;
- muestra de lectura inicial de los tres paquetes;
- bitácora metodológica de la parte 2.

### Resultado de la Parte 2

La inspección se transformó en una **extracción controlada, auditable y reproducible**.

Los tres paquetes 2022 **no** debían sumarse mecánicamente como si fueran universos independientes. Para evitar duplicación conceptual y empírica, se adoptó una decisión metodológica prudente:

### Decisión de ensamblaje

- **Base principal de análisis:** archivo de *todos los procesos*.
- **Subconjuntos comparativos:** *subasta inversa electrónica* y *contratación directa*.

Esta decisión permitió distinguir entre universo general y subconjuntos específicos, en lugar de producir una base artificialmente inflada.

A partir del archivo principal se desarrollaron las siguientes operaciones:

1. normalización de nombres de columnas;
2. identificación semiautomática de variables clave;
3. tipificación de montos y fechas;
4. creación de una llave analítica de convocatoria;
5. limpieza básica de la descripción del proceso;
6. construcción de una tabla de trabajo con variables sustantivas.

Variables centrales: entidad, tipo de entidad, código de convocatoria, descripción del proceso, tipo de compra, objeto contractual, sistema de contratación, monto referencial, moneda, departamento, provincia, distrito y fechas de convocatoria.

| Indicador | Valor |
|---|---|
| Registros totales | 67,889 |
| Convocatorias únicas | 59,381 |
| Entidades únicas | 2,804 |
| Objetos contractuales observados | 4 |
| Monto referencial con dato | 67,889 |
| Monto promedio | 1,771,160.71 |
| Monto mediano | 189,911.67 |

La base principal no solo es estructuralmente consistente, sino suficientemente densa como para sostener una lectura exploratoria inicial del módulo de convocatorias.

| Objeto contractual | Registros | Porcentaje |
|---|---|---|
| Bien | 32,868 | 48.41 % |
| Servicio | 22,742 | 33.50 % |
| Obra | 7,946 | 11.71 % |
| Consultoría de Obra | 4,333 | 6.38 % |

**Lectura inicial**

El universo 2022 se concentra en bienes y servicios, mientras que obra y consultoría de obra representan subconjuntos menores pero relevantes para análisis sectorial posterior.

| Entidad | Registros |
|---|---|
| SEGURO SOCIAL DE SALUD | 2,171 |
| ORGANISMO DE EVALUACIÓN Y FISCALIZACIÓN AMBIENTAL | 1,469 |
| EJÉRCITO PERUANO | 1,233 |
| FUERZA AÉREA DEL PERÚ | 955 |
| PETRÓLEOS DEL PERÚ S.A. | 671 |
| MINISTERIO DE CULTURA | 649 |
| CENARES | 592 |
| GOBIERNO REGIONAL DE PUNO – SEDE CENTRAL | 559 |
| MARINA DE GUERRA DEL PERÚ | 527 |
| PROCIENCIA | 502 |

| Departamento | Registros |
|---|---|
| Lima | 18,564 |
| Cusco | 6,465 |
| Áncash | 4,113 |
| Puno | 3,030 |
| Piura | 2,937 |
| Arequipa | 2,802 |
| La Libertad | 2,544 |
| Cajamarca | 2,510 |
| Junín | 2,413 |
| Ayacucho | 2,265 |

La distribución territorial muestra un fuerte peso de Lima, pero también una presencia importante de territorios fuera de la capital, lo que sugiere potencial para análisis descentralizado de compras públicas.

Se realizó una limpieza básica de la variable `descripcion_proceso` para explorar el vocabulario administrativo más recurrente. Entre los términos más frecuentes aparecieron:

| | | | |
|---|---|---|---|
| `distrito` | `provincia` | `departamento` | `mejoramiento` |
| `ejecucion` | `proyecto` | `mantenimiento` | `cusco` |
| `creacion` | `centro` | `agua` | `salud` |

La exploración textual no reemplaza un análisis NLP más profundo, pero sí muestra que el corpus administrativo del portal puede ser tratado con herramientas de texto en fases posteriores.

## Lo que se demostró

1. la base de datos podía cambiarse con justificación metodológica clara;
2. el portal seleccionado podía inspeccionarse y documentarse estructuralmente;
3. el tipo de fuente y el patrón de descarga podían verificarse;
4. era posible construir un scraper controlado y auditable sobre un subconjunto anual;
5. los archivos descargados podían transformarse en una base administrativa analizable.

## Lo que deliberadamente no se hizo

No se intentó descargar todo el portal ni producir inferencias causales. La tarea se concentró en un ejercicio de **captura, ensamblaje y exploración inicial**.

| Requerimiento del profesor | Cómo se respondió |
|---|---|
| Justificar el cambio de base | Se explicó el tránsito ENAHO $\rightarrow$ OECE desde una lógica de scraping, automatización y gestión pública. |
| Señalar enlaces | Se documentaron el portal principal, la subpágina de convocatorias y la referencia institucional en `gob.pe`. |
| Verificar el tipo de código fuente | Se compararon HTML bruto y HTML renderizado, identificando una interfaz `text/html` con capa dinámica. |
| Explicar paso a paso el scrapeo | Se organizó el proceso en tres partes: inspección, descarga controlada, auditoría y ensamblaje. |

1. La Tarea 2 confirmó que el módulo *Datos de la Convocatoria o Invitación* del portal OECE puede convertirse en una **fuente administrativa operativa** para análisis aplicado en gestión pública.
2. El trabajo mostró que el scraping no comienza con el click, sino con la **delimitación del objeto, la inspección estructural y la verificación del tipo de fuente**.
3. La estrategia de trabajar en tres partes dentro de un mismo Colab permitió mantener un flujo de trabajo **modesto, claro, auditado y reproducible**.
4. La tarea no agotó el portal OECE, pero dejó construida una base metodológica sólida para ampliar la extracción en fases posteriores o para derivarla hacia el trabajo final.

Fundamentos de Programación para IA Generativa. *Indicaciones para la Tarea Calificada 2 y Trabajo Final*. Documento del curso.

Programa de Especialización en Inteligencia Artificial Generativa aplicada a CCSS y Gestión Pública. *Fundamentos de Programación para IA Generativa Aplicada*. Syllabus del curso.

Pacheco Rojas, E. *Tarea 2.ipynb / tarea_2.py*. Material reproducible elaborado en Google Colab.

Portal de Datos Abiertos del OECE. Portal principal.
`https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:datosabiertos.html/content?userid=public&pa`

Portal de Datos Abiertos del OECE. Subpágina *Datos de la Convocatoria o Invitación*.
`https://bi.seace.gob.pe/pentaho/api/repos/:public:portal:dataset.html/content?userid=public&password`

Gobierno del Perú. *Acceder al portal de datos abiertos del OSCE*.
`https://www.gob.pe/14272-acceder-al-portal-de-datos-abiertos-del-osce`

# Gracias

Tarea Calificada 2 cerrada con flujo reproducible, estructura documentada y base analítica inicial.